

CONTESTO DETTAGLIATO PER AI LOCALE

Argomento scelto: Prototipo RAG locale per uno studio digitale

Documento pensato per essere caricato come base di conoscenza in un sistema AI locale.

Campo	Dettaglio
Versione documento	1.0
Scopo	Fornire contesto operativo, tecnico e comunicativo a un assistente AI locale che deve rispondere su un progetto RAG aziendale.
Formato ideale di uso	Embedding in vector database, retrieval per sezioni, risposta sintetica con citazione della fonte interna.
Pubblico previsto	Sviluppatori junior, project manager, stakeholder non tecnici e cliente pilota.
Lingua risposta AI	Italiano chiaro, concreto, con spiegazioni progressive e senza eccesso di gergo.

Nota importante: questo documento contiene dati e scenari inventati ma realistici. Puoi sostituire nomi, servizi, policy e dettagli con quelli reali della tua azienda.

1. Identita del progetto

Il progetto si chiama StudioRAG Local Assistant. E un prototipo di assistente AI locale pensato per uno studio digitale che vuole interrogare documenti interni, FAQ, procedure e conoscenza aziendale senza inviare dati sensibili a servizi cloud esterni. L obiettivo non e creare un modello da zero, ma costruire un sistema RAG: recupero di documenti pertinenti, passaggio del contesto al modello locale e generazione di una risposta utile.

Campo	Dettaglio
Nome progetto	StudioRAG Local Assistant
Tipo sistema	Assistente AI locale con Retrieval Augmented Generation
Ambiente principale	Mac o workstation locale, backend Node.js o Python, vector database Qdrant
Modello LLM	Modello locale compatibile con Ollama, LM Studio o runtime equivalente
Modello embedding	Embedding locale per trasformare documenti e query in vettori
Output richiesto	Risposte pratiche, fondate sulle fonti interne, con limite chiaro quando il contesto non basta

2. Obiettivi principali

- Rispondere su documenti aziendali:** l AI deve cercare nel materiale interno e rispondere solo quando trova informazioni rilevanti.
- Ridurre domande ripetitive:** deve aiutare su procedure, policy, onboarding, servizi, preventivi e dubbi tecnici frequenti.
- Proteggere i dati:** il sistema deve funzionare in locale o in infrastruttura controllata, evitando invio automatico di dati sensibili a servizi esterni.
- Essere comprensibile:** la risposta deve essere chiara anche per chi non e tecnico, ma abbastanza precisa per uno sviluppatore junior.
- Essere prototipabile:** la prima versione deve essere semplice, dimostrabile e migliorabile senza costruire subito un prodotto enorme.

3. Cosa il sistema deve sapere

Area	Informazioni da conoscere	Esempio di risposta attesa
Servizi dello studio	Siti web, e-commerce, branding, automazioni, AI locale, dashboard interne.	Lo studio puo sviluppare un sito vetrina, un e-commerce WooCommerce o un prototipo AI locale.
Procedure interne	Come gestire richieste cliente, raccolta materiali, stima tempi, consegne, revisioni.	Prima di stimare un progetto bisogna chiarire obiettivi, pagine, contenuti, funzionalita e deadline.
Stack tecnico	React, Node.js, ASP.NET, NestJS, WordPress, PostgreSQL, Qdrant, Docker.	Per un prototipo RAG junior-friendly si puo partire con Node/Express, Qdrant e Ollama.
Policy comunicazione	Tono professionale, diretto, non promettere funzionalita non confermate.	Posso proporti una stima indicativa, ma serve una call tecnica per confermare tempi e costi.
Limiti AI	L AI non deve inventare dati, prezzi, scadenze o policy assenti dal contesto.	Non trovo questa informazione nei documenti disponibili. Serve verifica interna.

4. Glossario operativo

Termine	Definizione semplice	Nota per l AI
RAG	Tecnica in cui l AI recupera documenti utili e li usa come contesto per rispondere.	Non confondere RAG con fine-tuning.

Embedding	Rappresentazione numerica di un testo, utile per trovare testi semanticamente simili.	Spiegare con analogia: coordinate del significato.
Vector database	Database che salva vettori e permette ricerca per similarita.	Esempio: Qdrant.
Chunk	Piccolo pezzo di documento indicizzato singolarmente.	Chunk troppo lunghi peggiorano precisione; troppo brevi perdono contesto.
LLM locale	Modello linguistico eseguito su macchina locale o server privato.	Non garantisce privacy assoluta: dipende anche da log, rete e configurazioni.
Prompt di sistema	Istruzioni stabili che guidano comportamento, tono e limiti dell AI.	Deve dire di non inventare informazioni.
Retrieval	Fase in cui il sistema cerca documenti pertinenti alla domanda.	Deve avvenire prima della generazione.

5. Architettura consigliata

La versione prototipo deve privilegiare chiarezza e dimostrabilit . Non serve integrare subito autenticazione complessa, ruoli, analytics avanzati o pannelli di amministrazione completi. La prima demo deve mostrare: caricamento documenti, indicizzazione, domanda utente, recupero fonti e risposta generata.

Componente	Ruolo	Scelta consigliata per prototipo
Frontend	Interfaccia chat e pagina fonti.	React/Vite mobile-first, UI semplice con campo domanda e lista fonti.
Backend	API per chat, embedding, ingestione file e retrieval.	Node.js/Express o NestJS se si vuole struttura piu scalabile.
LLM locale	Genera risposta finale usando contesto recuperato.	Ollama con modello compatibile alla macchina disponibile.
Embedding model	Converte testo e domande in vettori.	Modello embedding locale leggero e stabile.
Vector DB	Salva chunk e vettori.	Qdrant locale via Docker.
Storage documenti	Conserva file originali o testo estratto.	Cartella locale o database relazionale se serve tracciamento.
Database app	Utenti, chat, log, metadati.	PostgreSQL, opzionale nella primissima demo.

6. Flusso dati end-to-end

- Un operatore carica PDF, TXT, Markdown, CSV o pagine interne esportate.
- Il backend estrae il testo e lo divide in chunk con metadati: titolo, sezione, fonte, data, categoria.
- Ogni chunk viene trasformato in embedding tramite modello locale.
- I vettori vengono salvati in Qdrant insieme al testo originale e ai metadati.
- Quando l utente fa una domanda, anche la domanda viene trasformata in embedding.
- Qdrant restituisce i chunk piu simili semanticamente alla domanda.
- Il backend costruisce un prompt con: istruzioni, domanda utente, contesto recuperato e regole anti-invenzione.
- Il modello locale genera la risposta, citando o almeno elencando le fonti interne usate.
- Se i chunk non sono sufficienti, l AI deve dichiarare il limite invece di indovinare.

7. Regole di comportamento dell assistente

Regola	Descrizione	Esempio
Non inventare	Se una risposta non � nel contesto, dichiararlo.	Non ho trovato questa informazione nei documenti indicizzati.
Citare fonti interne	Quando possibile mostrare titolo documento o sezione usata.	Fonte interna: Procedura preventivi - sezione 2.
Separare fatto e consiglio	Distinguere cio che � documentato da	Dai documenti risulta X. Come

	cio che e suggerito.	suggerimento operativo, farei Y.
Rispondere in modo progressivo	Prima sintesi, poi dettagli, poi eventuali passi pratici.	In breve... Nel dettaglio... Prossimi passi...
Evitare gergo inutile	Usare termini tecnici solo quando servono e spiegarli.	Un embedding e una specie di impronta matematica del testo.
Proteggere dati sensibili	Non esporre credenziali, token, dati personali o informazioni non necessarie.	Non posso mostrare password o chiavi API. Posso spiegare dove configurarle.

8. Dataset iniziale consigliato

Per una demo efficace, il dataset iniziale non deve essere enorme. Meglio pochi documenti ben organizzati che centinaia di file sporchi. Ogni documento dovrebbe avere titolo chiaro, data, versione e sezione.

Documento	Contenuto	Priorita
Profilo studio	Chi siamo, servizi, tono, clienti tipici, posizionamento.	Alta
FAQ clienti	Domande frequenti su tempi, costi, revisioni, manutenzione, hosting.	Alta
Procedure progetto web	Brief, raccolta materiali, sviluppo, testing, go-live.	Alta
Stack tecnico interno	Tecnologie usate, quando scegliere WordPress, React, Node, ASP.NET.	Alta
Policy privacy AI	Cosa puo essere caricato, cosa no, gestione log e dati sensibili.	Molto alta
Template preventivo	Voci ricorrenti, esclusioni, ipotesi, condizioni.	Media
Manuale onboarding	Setup ambiente dev, Git, naming branch, strumenti interni.	Media

9. Esempi di contenuto aziendale fittizio

9.1 Profilo dello studio

Studio NovaDigitale e uno studio immaginario specializzato in siti web, e-commerce, identita visiva, automazioni leggere e prototipi AI locali. Il team preferisce soluzioni semplici da mantenere, interfacce chiare e codice comprensibile. La priorita e creare prodotti utili al cliente, evitando complessita tecnica non necessaria nella fase iniziale.

9.2 Servizi principali

- Siti vetrina per aziende locali, professionisti e associazioni.
- E-commerce basati su WooCommerce o soluzioni custom quando il catalogo e piu complesso.
- Dashboard interne per gestione contenuti, report o dati operativi.
- Prototipi AI locali per interrogare documentazione, procedure e knowledge base aziendali.
- Supporto tecnico e manutenzione post-lancio con pacchetti mensili.

9.3 Metodo di lavoro

- Brief iniziale con obiettivi, target, funzionalita e vincoli.
- Raccolta materiali: loghi, testi, immagini, accessi, riferimenti grafici.
- Proposta tecnica con stack, fasi, tempi e rischi.
- Sviluppo prototipo navigabile prima della versione finale.
- Revisione cliente con massimo due giri inclusi nella stima base.
- Testing finale su mobile, desktop, performance e contenuti.
- Consegna con mini guida o call di formazione.

10. FAQ da usare come conoscenza

Che cos e un prototipo RAG locale?

E una demo di assistente AI che cerca informazioni in documenti aziendali e genera risposte usando un modello eseguito in locale o su server privato.

Serve addestrare un modello?

No, per il prototipo non serve addestrare un modello. Si usa un modello gia pronto e si aggiunge il recupero documentale tramite embedding e vector database.

Quali file si possono caricare?

Nella versione iniziale sono consigliati TXT, Markdown, CSV e PDF testuali. I PDF scansionati richiedono OCR e possono essere meno affidabili.

Quanto conta la qualita dei documenti?

Moltissimo. Documenti chiari, brevi, aggiornati e ben divisi migliorano molto le risposte.

L AI locale e sempre privata?

E piu controllabile di una soluzione cloud, ma la privacy dipende da configurazione, log, rete, backup e gestione degli accessi.

Cosa succede se l AI non trova la risposta?

Deve dirlo chiaramente e proporre di aggiornare la knowledge base o chiedere verifica a un referente umano.

Meglio Node, NestJS, Python o ASP.NET?

Per prototipo rapido Node/Express o Python sono semplici. NestJS e ASP.NET sono piu strutturati se il progetto deve crescere.

Qdrant e obbligatorio?

No, ma e una scelta pratica per salvare vettori e fare ricerca semantica in locale.

Come si misura la qualita?

Con test di domande reali, controllo delle fonti recuperate, tasso di risposte corrette e casi in cui l AI ammette di non sapere.

11. Prompt di sistema consigliato

Usa questo blocco come base per il system prompt del prototipo:

Sei StudioRAG Local Assistant, un assistente AI locale per uno studio digitale. Rispondi in italiano chiaro e concreto. Usa prima di tutto il contesto recuperato dai documenti interni. Non inventare informazioni non presenti nel contesto. Se il contesto non basta, dillo apertamente e suggerisci quale informazione serve aggiungere. Quando rispondi, distingui tra dati documentati e suggerimenti operativi. Mantieni un tono professionale, amichevole e utile. Evita frasi troppo lunghe. Quando la domanda e tecnica, spiega passo passo e usa esempi semplici. Non mostrare dati sensibili, password, token o chiavi API.

12. Template risposta ideale

Le risposte dovrebbero seguire una struttura prevedibile, cosi l utente capisce subito cosa e certo e cosa va verificato.

Parte	Quando usarla	Esempio
Sintesi	Sempre, nelle prime 2-3 righe.	In breve: per questa esigenza conviene partire con un prototipo RAG semplice.

Dettaglio	Quando la domanda richiede spiegazione.	Il sistema indicizza i documenti, recupera i chunk pertinenti e passa il contesto al modello.
Fonte interna	Quando il retrieval fornisce documenti.	Fonti usate: FAQ AI locale, Procedura progetto web.
Limite	Quando mancano dati.	Nel contesto non trovo tempi o prezzi ufficiali.
Passi successivi	Quando serve azione pratica.	Prossimo passo: preparare 10 documenti puliti e 20 domande di test.

13. Casi d uso prioritari

Caso d uso	Utente	Valore	Esempio domanda
Onboarding sviluppatore	Junior dev	Riduce tempo per capire progetto e stack.	Come avvio il backend del prototipo?
Supporto commerciale	Project manager	Aiuta a rispondere a richieste ricorrenti.	Cosa includiamo in un prototipo AI locale?
Knowledge base cliente	Cliente pilota	Permette domande sui propri documenti.	Qual e la procedura per aprire un ticket?
Ricerca interna	Team operativo	Trova rapidamente policy e procedure.	Quanti giri di revisione sono inclusi?
Supporto tecnico	Sviluppatore	Spiega scelte tecniche e limiti.	Perche il retrieval non trova il documento giusto?

14. Criteri di qualita della demo

- La demo deve rispondere correttamente ad almeno 15 domande su 20 preparate prima.
- Ogni risposta importante deve mostrare quali fonti interne sono state usate.
- L AI deve rifiutare o limitare la risposta quando il contesto non contiene dati sufficienti.
- Il tempo di risposta deve essere accettabile per una demo live, anche se non perfetto.
- L interfaccia deve essere semplice: domanda, risposta, fonti, eventuale storico.
- Il sistema deve essere spiegabile a un cliente non tecnico in meno di 5 minuti.

15. Errori comuni da evitare

Errore	Conseguenza	Prevenzione
Caricare troppi file sporchi	Risposte confuse e retrieval impreciso.	Partire da pochi documenti puliti e aggiornati.
Chunk senza metadati	Difficile mostrare fonti e debug.	Salvare titolo, sezione, categoria e data.
Prompt troppo generico	L AI inventa o divaga.	Inserire regole chiare: non inventare, cita fonti, dichiara limiti.
Nessun set di test	Non si capisce se il sistema migliora.	Preparare domande attese e confrontare risposte.
Pensare che locale significhi automaticamente sicuro	Rischi su log, permessi, backup e rete.	Definire policy privacy e accessi.
Integrare tutto subito	Progetto lento e difficile da mostrare.	Costruire prima una demo minima ma funzionante.

16. Mini specifica tecnica della prima versione

Funzionalità	Inclusa in V1	Note
Chat con AI locale	Si	Campo input, risposta testuale, gestione loading.
Upload documenti	Si	Inizialmente TXT, MD, CSV e PDF

		testuali.
Indicizzazione automatica	Si	Chunking + embedding + salvataggio su Qdrant.
Fonti nella risposta	Si	Mostrare titolo documento e punteggio se utile.
Storico conversazioni	Opzionale	Si può rimandare se la demo è solo live.
Login utenti	No in V1	Da aggiungere quando il prodotto cresce.
Dashboard admin	No in V1	Basta una pagina semplice o script ingest.
Deploy server	Opzionale	Per demo locale basta Docker + script avvio.

17. Esempi di domande di test

- Che cos'è StudioRAG Local Assistant?
- Quali file posso caricare nella prima versione?
- Perché non serve fare fine-tuning per il prototipo?
- Qual è la differenza tra RAG ed embedding?
- Come gestiamo i dati sensibili?
- Quali sono i passaggi per indicizzare un documento?
- Cosa deve fare l'AI se non trova una risposta?
- Quale stack consigliate per una demo junior-friendly?
- Quali sono gli errori da evitare nella prima demo?
- Come posso spiegare il progetto a un cliente non tecnico?

18. Esempi di risposte attese

Domanda: Qual è la differenza tra RAG e fine-tuning?

Risposta attesa: Il RAG non cambia il modello. Recupera documenti pertinenti e li passa al modello come contesto al momento della domanda. Il fine-tuning, invece, modifica o adatta il modello con un addestramento aggiuntivo. Per il prototipo StudioRAG è preferibile il RAG perché è più rapido, aggiornabile e adatto a documenti aziendali che cambiano.

Domanda: L'AI può rispondere se una policy non è nei documenti?

Risposta attesa: No, non dovrebbe inventare. Deve dire che non trova la policy nei documenti indicizzati e suggerire di aggiungere o aggiornare la fonte interna. Può eventualmente proporre una bozza operativa, ma deve marcarla come suggerimento non ufficiale.

Domanda: Come spiego Qdrant a un cliente?

Risposta attesa: Qdrant è un database pensato per cercare testi simili per significato, non solo per parole uguali. In pratica salva una rappresentazione numerica dei documenti e permette all'AI di recuperare i pezzi più pertinenti alla domanda.

19. Privacy, sicurezza e limiti

- Non caricare password, token, chiavi API o credenziali nei documenti della knowledge base.
- Evitare dati personali non necessari, soprattutto se il prototipo viene mostrato a terzi.
- Disattivare log completi delle conversazioni se contengono dati sensibili o applicare mascheramento.
- Separare dataset di demo e dataset reale.
- Usare backup e permessi coerenti con il livello di riservatezza dei documenti.
- Chiarire sempre che una demo locale non sostituisce una revisione legale o security audit.

20. Roadmap suggerita

Fase	Obiettivo	Output
Fase 1	Preparare dataset demo e domande di test.	10 documenti puliti + 20 domande.
Fase 2	Creare backend ingest + Qdrant.	Script indicizzazione funzionante.
Fase 3	Creare endpoint chat.	Domanda -> retrieval -> risposta.
Fase 4	Creare interfaccia mobile-first.	Pagina chat con fonti.
Fase 5	Testare qualità e limiti.	Report con domande corrette, errate e fonti mancanti.
Fase 6	Preparare demo cliente.	Scenario guidato di 5 minuti.

21. Checklist finale per import in AI locale

- Dividere il documento in sezioni prima dell'embedding.
- Mantenere i titoli come metadati.
- Usare chunk di dimensione media e overlap moderato.
- Salvare fonte, sezione, versione e categoria per ogni chunk.
- Preparare domande di test prima di mostrare la demo.
- Verificare che le risposte citino fonti interne.
- Aggiornare il prompt di sistema se l'AI inventa o risponde troppo genericamente.
- Aggiornare i documenti quando emergono domande senza risposta.

Fine documento. Questo PDF può essere usato come contesto iniziale, dataset dimostrativo o base per creare chunk da indicizzare in un sistema RAG locale.